

## Рубежный контроль №2.

### Пасатюк Александра ИУ5-63Б

### Вариант 16

**Задание.** Для заданного набора данных (по варианту) построить модели классификации или регрессии (в зависимости от конкретной задачи, рассматриваемой в наборе данных). Для построения моделей использовать дерево решений и случайный лес. Оцените качество моделей на основе подходящих метрик качества (не менее двух метрик). Какие метрики качества Вы использовали и почему? Какие выводы Вы можете сделать о качестве построенных моделей? Для построения моделей необходимо выполнить требуемую предобработку данных: заполнение пропусков, кодирование категориальных признаков, и т.д.

- При решении задач можно выбирать любое подмножество признаков из приведенного набора данных.
- Для сокращения времени построения моделей можно использовать фрагмент набора данных (например, первые 200-500 строк).

### Выполнение задания

#### Импорт библиотек

```
: import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
```

#### Загрузка и первичная обработка данных:

```
: # загрузка набора данных
data = pd.read_csv('restaurant-scores-lives-standard.csv', sep=",")
# размер набора данных
data.shape
```

```
: (53973, 23)
```

```
: # первые 5 строк набора данных
data.head()
```

```
:
   business_id  business_name  business_address  business_city  business_state  business_postal_code  business_latitude  business_longitude  business_location  business_phone_nui
0      101192    Cochinita #2    2 Marina Blvd  San Francisco      CA              NaN              NaN              NaN              NaN              1.415043
1      97975    BREADBELLY    1408 Clement St  San Francisco      CA              94118              NaN              NaN              NaN              1.415724
2      92982    Great Gold  3161 24th St.  San Francisco      CA              94110              NaN              NaN              NaN              NaN
3     101389    HOMAGE    214 CALIFORNIA  San Francisco      CA              94111              NaN              NaN              NaN              1.415488
4      85986    Pronto Pizza    798 Eddy St  San Francisco      CA              94109              NaN              NaN              NaN              NaN
```

5 rows × 23 columns

```
: # проверим, есть ли пропущенные значения
data.isnull().sum()
```

```

: business_id          0
  business_name        0
  business_address      0
  business_city         0
  business_state        0
  business_postal_code 1018
  business_latitude     19556
  business_longitude    19556
  business_location     19556
  business_phone_number 36938
  inspection_id         0
  inspection_date       0
  inspection_score      13610
  inspection_type       0
  violation_id          12870
  violation_description  12870
  risk_category         12870
  Neighborhoods (old)   19594
  Police Districts     19594
  Supervisor Districts 19594
  Fire Prevention Districts 19646
  Zip Codes            19576
  Analysis Neighborhoods 19594
dtype: int64

: # уникальные значения столбца 'category_group' файла impeachment_topline
data['Analysis Neighborhoods'].unique()

: array([nan, 34., 36., 9., 23., 20., 8., 25., 1., 13., 35., 32., 39.,
        12., 26., 22., 7., 6., 10., 14., 5., 21., 29., 28., 11., 30.,
         2., 3., 15., 4., 31., 18., 41., 16., 24., 27., 40., 17., 19.,
        33., 37., 38.])

: # удаление колонок неподходящих для построения моделей
data.drop(['business_id', 'business_name', 'business_address', 'business_city', 'business_state', 'business_postal_code', 'business_latitude', 'business_longitude', 'business_location', 'business_phone_number'], axis=1, inplace=True)

: data.head()

:


|   | inspection_score | violation_description                             | risk_category | Neighborhoods (old) | Police Districts | Supervisor Districts | Fire Prevention Districts | Analysis Neighborhoods |
|---|------------------|---------------------------------------------------|---------------|---------------------|------------------|----------------------|---------------------------|------------------------|
| 0 | NaN              |                                                   | NaN           | NaN                 | NaN              | NaN                  | NaN                       | NaN                    |
| 1 | 96.0             | Inadequately cleaned or sanitized food contact... | Moderate Risk | NaN                 | NaN              | NaN                  | NaN                       | NaN                    |
| 2 | NaN              |                                                   | NaN           | NaN                 | NaN              | NaN                  | NaN                       | NaN                    |
| 3 | NaN              |                                                   | NaN           | NaN                 | NaN              | NaN                  | NaN                       | NaN                    |
| 4 | NaN              | High risk vermin infestation                      | High Risk     | NaN                 | NaN              | NaN                  | NaN                       | NaN                    |



: # удаление строк, содержащих пустые значения в колонке целевого признака
data.dropna(axis=0, subset=['Analysis Neighborhoods'], inplace=True)
# размер данных
data.shape

: (34379, 8)

: data.head()

:


|    | inspection_score | violation_description                              | risk_category | Neighborhoods (old) | Police Districts | Supervisor Districts | Fire Prevention Districts | Analysis Neighborhoods |
|----|------------------|----------------------------------------------------|---------------|---------------------|------------------|----------------------|---------------------------|------------------------|
| 11 | 71.0             | Improper storage use or identification of toxic... | Low Risk      | 34.0                | 2.0              | 9.0                  | 6.0                       | 34.0                   |
| 16 | 84.0             | Moderate risk food holding temperature             | Moderate Risk | 36.0                | 9.0              | 9.0                  | 7.0                       | 36.0                   |
| 30 | NaN              |                                                    | NaN           | 10.0                | 9.0              | 11.0                 | 7.0                       | 9.0                    |
| 55 | NaN              | Unapproved or unmaintained equipment or utensils   | Low Risk      | 36.0                | 9.0              | 9.0                  | 7.0                       | 36.0                   |
| 64 | 92.0             | Inadequate and inaccessible handwashing facilities | Moderate Risk | 23.0                | 1.0              | 10.0                 | 3.0                       | 23.0                   |



: # проверим, есть ли пропущенные значения
data.isnull().sum()

: inspection_score      7262
  violation_description  7232
  risk_category         7232
  Neighborhoods (old)    0
  Police Districts       0
  Supervisor Districts   0
  Fire Prevention Districts 52
  Analysis Neighborhoods 0
dtype: int64

: # удаление строк, содержащих пустые значения в колонках
data.dropna(axis=0, subset=['Police Districts'], inplace=True)
data.dropna(axis=0, subset=['violation_description'], inplace=True)
data.dropna(axis=0, subset=['inspection_score'], inplace=True)
data.dropna(axis=0, subset=['Fire Prevention Districts'], inplace=True)
# размер данных
data.shape

: (25812, 8)

```



```

: from sklearn.preprocessing import LabelEncoder, OneHotEncoder
: le = LabelEncoder()
: category = le.fit_transform(data['risk_category'])
: discr = le.fit_transform(data['violation_description'])
: data['risk_category'] = category
: data['violation_description'] = discr
: data.head()

```

```

: array(['Low Risk', 'Moderate Risk', 'High Risk'], dtype=object)

```

```

: np.unique(category)

```

```

: array([0, 1, 2])

```

```

: data['violation_description'].unique()

```

```

: array(['Noncompliance', 'Lack Infrastructure', 'Hygiene', 'Legal'],
:       dtype=object)

```

```

: np.unique(discr)

```

```

: array([0, 1, 2, 3])

```

```

: data['risk_category'] = category
: data['violation_description'] = discr
: data.head()

```

	inspection_score	violation_description	risk_category	Neighborhoods (old)	Police Districts	Supervisor Districts	Fire Prevention Districts	Analysis Neighborhoods	
11	71.0		3	1	34.0	2.0	9.0	6.0	34.0
16	84.0		3	2	36.0	9.0	9.0	7.0	36.0
64	92.0		1	2	23.0	1.0	10.0	3.0	23.0
73	92.0		3	2	34.0	2.0	9.0	12.0	34.0
92	74.0		0	2	6.0	1.0	10.0	3.0	8.0

```

: # Масштабирование данных
: from sklearn.preprocessing import MinMaxScaler
: sc1 = MinMaxScaler()
: sc1_data = sc1.fit_transform(data[['inspection_score']])
: data['inspection_score'] = sc1_data
: sc2_data = sc1.fit_transform(data[['Neighborhoods (old)']])
: data['Neighborhoods (old)'] = sc2_data
: sc3_data = sc1.fit_transform(data[['Police Districts']])
: data['Police Districts'] = sc3_data
: sc4_data = sc1.fit_transform(data[['Supervisor Districts']])
: data['Supervisor Districts'] = sc4_data
: sc5_data = sc1.fit_transform(data[['Fire Prevention Districts']])
: data['Fire Prevention Districts'] = sc5_data
: sc6_data = sc1.fit_transform(data[['violation_description']])
: data['violation_description'] = sc6_data
: sc7_data = sc1.fit_transform(data[['risk_category']])
: data['risk_category'] = sc7_data
: sc8_data = sc1.fit_transform(data[['Analysis Neighborhoods']])
: data['Analysis Neighborhoods'] = sc8_data
: data.head()

```

	inspection_score	violation_description	risk_category	Neighborhoods (old)	Police Districts	Supervisor Districts	Fire Prevention Districts	Analysis Neighborhoods	
11	0.462963		1.000000	0.5	0.825	0.111111	0.8	0.357143	0.825
16	0.703704		1.000000	1.0	0.875	0.888889	0.8	0.428571	0.875
64	0.851852		0.333333	1.0	0.550	0.000000	0.9	0.142857	0.550
73	0.851852		1.000000	1.0	0.825	0.111111	0.8	0.785714	0.825
92	0.518519		0.000000	1.0	0.125	0.000000	0.9	0.142857	0.175

```

: from sklearn.model_selection import train_test_split

```

```

: # Разделение данных на тестовую и обучающую выборки
: data_train, data_test, data_y_train, data_y_test = train_test_split(data[data.columns.drop('Analysis Neighborhoods')], data['Analysis Neighborhoods'],
:                             random_state=1)

```

## Модель "Дерево решений"

```

: from sklearn.tree import DecisionTreeRegressor
: dtc = DecisionTreeRegressor(random_state=1).fit(data_train, data_y_train)
: data_test_predicted_dtc = dtc.predict(data_test)

```

## Модель "Случайный лес"

```

: from sklearn.ensemble import RandomForestRegressor
: RF = RandomForestRegressor(random_state=1).fit(data_train, data_y_train)
: data_test_predicted_rf = RF.predict(data_test)

```

## Оценка качества моделей:

В качестве метрик для оценки качества моделей используем Mean squared error (средняя квадратичная ошибка), как наиболее часто используемую метрику для оценки качества регрессии, и метрику  $R^2$  (коэффициент детерминации), потому что эта метрика является нормированной.

```
: from sklearn.metrics import mean_squared_error, r2_score
# Mean squared error - средняя квадратичная ошибка
print('Метрика MSE:\nДерево решений: {}\nСлучайный лес: {}'.format(mean_squared_error(data_y_test, data_test_predicted_dtc), mean_squared_error(data_y_test, data_test_predicted_rf)))

Метрика MSE:
Дерево решений: 7.748334108166603e-07
Случайный лес: 3.951650395165032e-07

: # 4) Метрика R2 или коэффициент детерминации
print('Метрика R\u00B2:\nДерево решений: {}\nСлучайный лес: {}'.format(r2_score(data_y_test, data_test_predicted_dtc), r2_score(data_y_test, data_test_predicted_rf)))

Метрика R²:
Дерево решений: 0.9999907284691102
Случайный лес: 0.9999952715192462
```

## Выводы о качестве построенных моделей:

Исходя из результатов первой метрики, можно сделать вывод что модель "Случайный лес" лучше справляется с задачей по сравнению с моделью "Дерево решений". По результатам второй метрики можно сказать, что переменные практически функционально зависимы.